

ELE075 - Trabalho Computacional III: ANFIS

Rúbia Reis Guerra

2013031143

09/12/2018

1 Introdução

O sistema de inferência nebulosa baseada em redes neurais adaptativas (ANFIS) é uma técnica neuro-fuzzy inteligente usada para modelar e controlar sistemas mal definidos e incertos. O ANFIS é baseado em pares de dados de entrada e saída do sistema em consideração [1]. Neste trabalho, será utilizado ANFIS em um problema de regressão (Parte I) e em três problemas de classificação de padrões (Parte II).

2 Parte I: Aproximação de Função

Foi projetado um sistema nebuloso adaptativo ANFIS do tipo Takagi-Sugeno de ordem 1 [2] para implementar um mapeamento não-linear de um espaço de entradas escalar para um espaço de saídas escalares de um sistema de inferência. O modelo típico de regras em um modelo nebuloso de Sugeno é:

Se a entrada x é $A1$ e a entrada y é $B2$, então a saída é $z = ax + by + c$

O principal objetivo foi obter uma aproximação para a função:

$$y = \text{seno}(x), \text{ para } x \in [0, 2\pi]$$

Utilizando as mesmas regras definidas para a aproximação da função $y = \text{cosseno}(x)$, realizada no trabalho anterior, tem-se:

1. Se $-\pi \leq x \leq -0.5$ então $y = x + \frac{\pi}{2}$
2. Se $-0.5 \leq x \leq 0.5$ então $y = x$
3. Se $0.5 \leq x \leq \pi - 0.5$ então $y = -x + \frac{\pi}{2}$
4. Se $\pi - 0.5 \leq x \leq \pi + 0.5$ então $y = -x$
5. Se $\pi + 0.5 \leq x \leq 2\pi - 0.5$ então $y = x - \frac{3\pi}{2}$

E as funções de pertinência gaussianas $\mu_i(x)$:

1. $\mu_1(x) = \text{gaussmf}(0.5284, -1.016)$
2. $\mu_2(x) = \text{gaussmf}(0.2466, 0.8089)$


$$3. \mu_3(x) = \text{gaussmf}(0.5283, 2.634)$$

$$4. \mu_4(x) = \text{gaussmf}(0.2467, 4.459)$$


$$5. \mu_5(x) = \text{gaussmf}(0.6395, 6.298)$$

O sistema foi avaliado utilizando a ferramenta *Fuzzy Logic Toolbox*, implementada em MATLAB, e os resultados podem ser observados na figura 1. O Erro Quadrático Médio foi de 0.0564, calculado a partir da relação:


$$EQM = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$




(a) Dados de entrada e função original




(b) Resultado antes do treinamento, $EMQ = 0.1703$



(c) Funções de pertinência antes do treinamento



(d) Funções de pertinência após o treinamento



(e) Resultado após o treinamento, $EMQ_{Teste} = 0.0564$

Figura 1: Resultados da regressão

3 Parte II: Classificador Binário Baseado em Regras Nebulosas

A segunda parte do trabalho consistiu em projetar sistemas adaptativos nebulosos aplicados à resolução de 3 problemas de classificação de padrões:

1. Dados Sintéticos 2D: referência para verificar se a estratégia proposta está funcionando corretamente;
2. Iris Species Data Set: o problema tem originalmente 3 classes, contudo, para fins de simplificação, considerou-se que o objetivo é distinguir a espécie “Iris-setosa” das outras duas espécies existentes;
3. Breast Cancer Wisconsin (Diagnostic) Data Set: base de dados contendo 569 amostras e 30 dimensões, contextualizada no diagnóstico de tumores de câncer de mama (maligno ou benigno) com base em análises da biópsia e de imagem.

Como o modelo fuzzy Takagi-Sugeno de ordem 1 foi inicialmente projetado para resolver problemas de Regressão, uma adaptação simples para a utilização do sistema ANFIS para tarefas de classificação é a definição de um limiar (τ_c) na saída do modelo:

$$\hat{y} = \begin{cases} 1, & \text{se } \hat{y} \geq \tau_c \\ 0, & \text{caso contrário} \end{cases} \quad (1)$$

De forma simplificada, o processo de classificação foi feito conforme o Algoritmo 1:

Algorithm 1 ANFIS para classificação de padrões

```
1  $max_{iter} \leftarrow 30$ 
2 for  $i = 1 : max_{iter}$  do
3   Treino, Teste  $\leftarrow$  StratifiedShuffleSplit(dados, rótulos, split=0.3)
4   Particionamento estratificado k-fold,  $k = 10$ 
5   Tuning de parâmetros  $mf, n\_rules$ 
6   Cálculo de  $mse_{treino,i}$ 
7   Treinamento com melhores parâmetros
8   Classificação:  $\hat{y}_{classes} = (\hat{y} > threshold)$ 
9   Cálculo de  $mse_{teste,i}$ 
10 end for
```

O refinamento de parâmetros consistiu em definir a melhor combinação de número de regras do ANFIS e tipo de função de pertinência. Foi validada cada combinação utilizando validação cruzada k-fold ($k = 10$), de forma que a combinação encontrada para o menor erro médio na validação foi utilizada para retreinar todos os dados de treinamento. Os possíveis valores para cada parâmetro foram:


- N_{rules} : 2, 3, 4
- mf : 'gaussmf', 'gauss2mf', 'gbellmf'

Ainda, em decorrência de análises empíricas, para cada dataset foram definidos os parâmetros para inicialização do modelo de inferência para treinamento e o limiar de classificação:

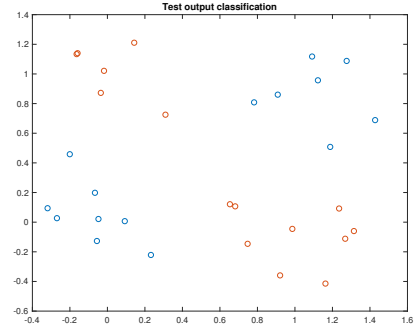
- Dataset 2D: *genfis1*, com consequente linear, e *anfis* com método de otimização híbrido, limiar de classificação = 0.8;
- Iris: *genfis3*, com modelo de Sugeno e 50 iterações máximas para FCM, e *anfis* com método de otimização híbrido, limiar de classificação = 0.5;
- Breast Cancer: *genfis3*, com modelo de Sugeno e 60 iterações máximas para FCM, e *anfis* com método de otimização *backpropagation*, limiar de classificação = 75;

3.1 Dataset 2D: Resultados

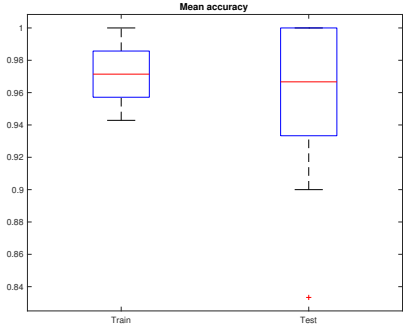
Na figura 2, observa-se os resultados da classificação de padrões utilizando o ANFIS projetado. Devido à alta separabilidade espacial das classes, os resultados de acurácia oscilaram próximos de 100%, validando a estratégia proposta. O número de regras nebulosas que maximizou os resultados foi de 4, enquanto a função de pertinência que mais se adequou ao sistema foi *gaussmf*. Observa-se, contudo, a variabilidade da função de classificação aproximada pelo ANFIS para a classe 1. Para contornar, foi necessária a definição do limiar de classificação em aproximadamente 0.8.



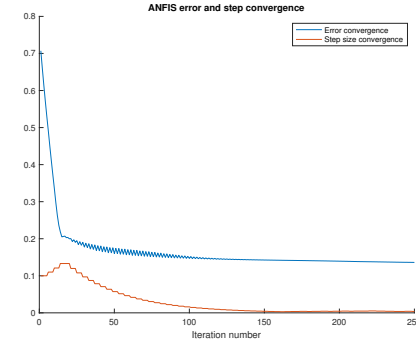
(a) Dados de entrada



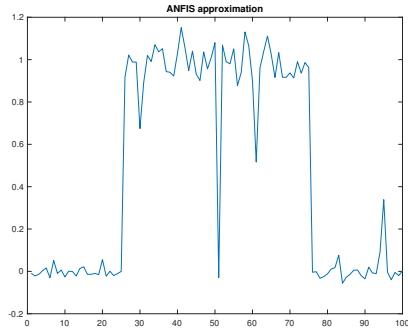
(b) Resultado da classificação (dados de teste)



(c) Acurácia média



(d) Convergência do treinamento após *tuning* de hiper-parâmetros




(e) Aproximação da função de classificação inferida pelo ANFIS

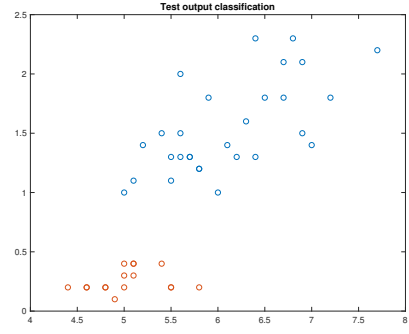
Figura 2: Dataset2d: Resultados da classificação

3.2 Iris: Resultados

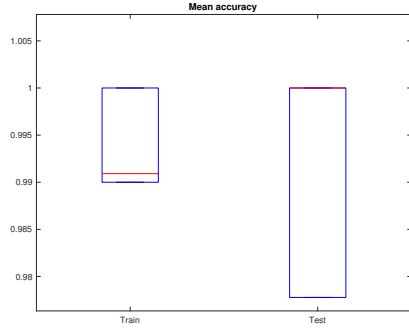
O segundo experimento consistiu em aplicar o ANFIS no dataset Iris [3], que contém 150 amostras (4 dimensões) sobre análises de pétalas e sépalas de diferentes espécies de flores. Como mencionado anteriormente, o problema original consiste de 3 classes, porém, neste trabalho foi considerada apenas a diferenciação da classe *iris – setosa* para as demais. Novamente, pela alta separabilidade espacial das classes em pelo menos uma das dimensões dos dados de entrada, os resultados de acurácia oscilaram próximos de 98%. Como pode ser visto na Figura 3e, o limiar de classificação em 0.5 atende ao conjunto de dados.



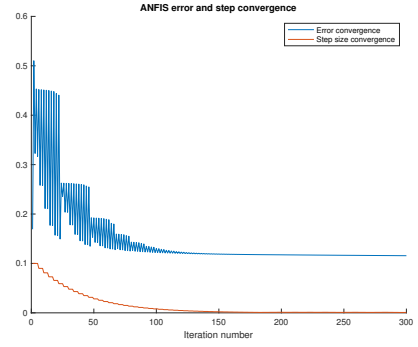
(a) Dados de entrada



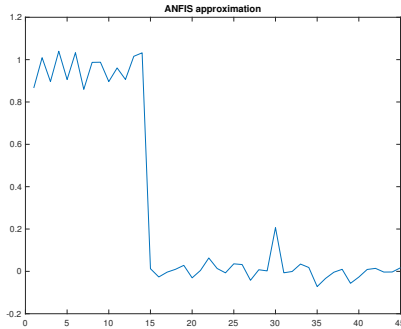
(b) Resultado da classificação (dados de teste)



(c) Acurácia média



(d) Convergência do treinamento após *tuning* de hiper-parâmetros




(e) Aproximação da função de classificação inferida pelo ANFIS


Figura 3: Iris: Resultados da classificação

3.3 Breast Cancer Wisconsin Dataset: Resultados

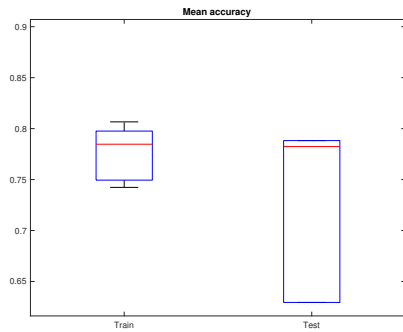
O terceiro experimento consistiu em aplicar o ANFIS no dataset Breast Cancer Wisconsin Data Set [4], que contém 569 amostras (30 dimensões) sobre análises de massas mamárias que constituem tumores malignos ou benignos. Neste problema, pela alta dimensionalidade e pela baixa separabilidade espacial das classes, a performance do sistema projeto foi consideravelmente pior (70%, Figura 4c. Ainda, como pode ser visto na Figura 4e, a aproximação da função de classificação, inferida pelo ANFIS, agregou ruído consideravelmente, dificultando a escolha de um limiar de classificação adequado. Por inspeção visual e testes empíricos, foi definido um limiar de 75.



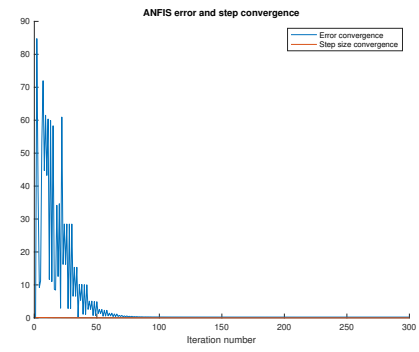
(a) Dados de entrada




(b) Resultado da classificação (dados de teste)



(c) Acurácia média



(d) Convergência do treinamento após *tuning* de hiper-parâmetros



(e) Aproximação da função de classificação inferida pelo ANFIS

Figura 4: Breast Cancer Wisconsin DS: Resultados da classificação

Referências

- [1] Buragohain, Mrinal and Mahanta, Chitralekha. *A novel approach for ANFIS modelling based on full factorial design*, *Applied Soft Computing*, Volume 8, Issue 1, 2008, Pages 609-625, ISSN 1568-4946.
- [2] Sugeno, M., *Industrial applications of fuzzy control*, Elsevier Science Pub. Co., 1985.
- [3] Iris-Setosa Data Set, UCI: <https://www.kaggle.com/uciml/iris>

- [4] Breast Cancer Wisconsin Diagnostic Data Set, UCI:
<https://www.kaggle.com/uciml/breast-cancer-wisconsin-data>
- [5] Jang, Jyh-Shing R, Chuen-Tsai Sun, and Eiji Mizutani. *Neuro-fuzzy and Soft Computing: A Computational Approach to Learning and Machine Intelligence*. Upper Saddle River, NJ: Prentice Hall, 1997.