Exercício 8: Seleção de Características

Rúbia Reis Guerra 2013031143

9 de junho de 2017

1 Seleção de Características

Nesta atividade, foi proposta a análise do dataset BCW (BreastCancer), implementando a seleção de características via Kmeans, F-Score e clustering hieráquico.

```
> rm(list=ls())
> library('MASS')
> library('mlbench')
> library('mclust')
> library('stats')
> fscore <- function(X,c1,c2,n){</pre>
    f \leftarrow c()
    for(i in 1:n)
      f[i] \leftarrow ((mean(c1[,i]) - mean(X[,i]))^2
                +(mean(c2[,i]) - mean(X[,i]))^2)/(sd(c1[,i])^2+sd(c2[,i])^2)
    return(f)
> ############################
> # Dataset BreastCancer #
> data(BreastCancer)
> X<- data.matrix(BreastCancer[,2:10])</pre>
> X[is.na(X)] <- 0
> Y <- as.numeric(BreastCancer$Class)
> c1 <- X[which(Y==1),]
> c2 <- X[which(Y==2),]
> N \leftarrow dim(X)[1]
> n \leftarrow dim(X)[2]
> clPairs(cbind(X,Y),Y)
```

```
> # F-Score #
> f <- fscore(X,c1,c2,n)
> f
 \hbox{\tt [1]} \ \ 1.1317247 \ \ 1.8363064 \ \ 1.8986351 \ \ 0.8488204 \ \ 0.8084139 \ \ 1.8652137 \ \ 1.3013896 
[8] 0.9282550 0.1973198
> ###############################
> # Kmeans #
> k <- list()
> for(i in 1:(nrow(t(X))-1))
+ {
    h \leftarrow kmeans(t(X),i)
   k[[i]] <- h$cluster
+ }
> k
[[1]]
   Cl.thickness
                       Cell.size
                                       Cell.shape
                                                     Marg.adhesion
                                                                       Epith.c.size
    Bare.nuclei
                     Bl.cromatin Normal.nucleoli
                                                            Mitoses
               1
                                1
                                                                  1
```

[[2]]				
Cl.thickness	Cell.size	Cell.shape	${ t Marg.adhesion}$	Epith.c.size
1	1	1	2	2
Bare.nuclei		Normal.nucleoli	Mitoses	
1	1	2	2	
[[3]]				
Cl.thickness	Cell.size	Cell.shape	Marg.adhesion	Epith.c.size
3	2	2	2	2
Bare.nuclei	Bl.cromatin	Normal.nucleoli	Mitoses	
3	2	2	1	
[[4]]				
Cl.thickness	Cell.size	Cell.shape	Marg.adhesion	Epith.c.size
4	3	3	3	3
Bare.nuclei	Bl.cromatin	Normal.nucleoli	Mitoses	
3	3	1	2	
[[[]]				
[[5]]	Cell.size	Coll abone	Marg.adhesion	Enith a gigo
Cl.thickness	Cell.Size	Cell.shape	marg.adnesion 2	Epith.c.size
Bare.nuclei		Normal.nucleoli	Mitoses	3
4	3	1	5	
-		_	· ·	
[[6]]				
Cl.thickness	Cell.size	Cell.shape	${\tt Marg.adhesion}$	Epith.c.size
3	2	2	1	2
Bare.nuclei		Normal.nucleoli	Mitoses	
4	2	6	5	
[[7]]				
Cl.thickness	Cell.size	Cell.shape	Marg.adhesion	Epith.c.size
6	2	2	7	4
Bare.nuclei	Bl.cromatin	Normal.nucleoli	Mitoses	
3	4	1	5	
[[8]]				
Cl.thickness	Cell.size	Cell.shape	Marg.adhesion	Epith.c.size
2	8	8	3	5
Bare.nuclei	Bl.cromatin	Normal.nucleoli	Mitoses	
4	6	7	1	

Analisando os resultados de clustering, pode-se ter uma noção da ordem de distinção espacial das características. Até 4 clusters, observamos que Cell.size,

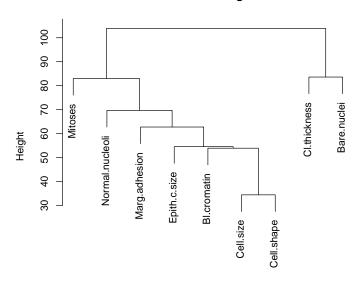
>

Cell.shape, Marg.adhesion, Epith.c.size, Bl.cromatin e Normal.nucleoli apresentam uma proximidade espacial significativa. Ainda, observa-se que Mitoses, Cl.thickness e Bare.nuclei estão distantes dos demais grupos. Porém, Cl.thickness e Bare.nuclei distanciam-se de todas as outras características e apresentam alguma proximidade entre si, enquanto Mitoses está mais próxima do cluster citado anteriormente.

>

- > # Hierarchical clustering #
- > clusters <- hclust(dist(t(X)))</pre>
- > plot(clusters)

Cluster Dendrogram

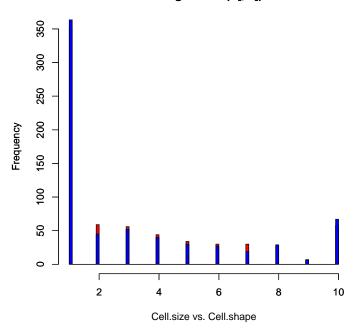


dist(t(X)) hclust (*, "complete")

A partir dos resultados acima, pode-se observar a redundância dos atributos Cell.size e Cell.shape. Os resultados de clustering via kmeans demonstram uma proximidade espacial das duas características - agrupadas repetidamente no mesmo cluster. A distribuição comparativa dos atributos é elicitada no histograma a seguir:

- > hist(t(X[,3]),col='red',xlab='Cell.size~vs.~Cell.shape',breaks=100,ylim=c(0,350))
- > par(new=T)
- > hist(t(X[,2]),col = 'blue', xlab='',breaks=100,ylim=c(0,350))

Histogram of t(X[, 2])



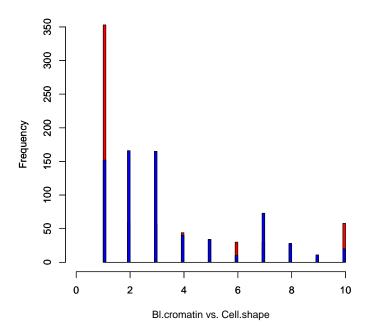
Caso seja neces-

sária a redução de dimensionalidade do problema, é possível afirmar que a eliminação de uma das caractéristicas citadas acima não irá impactar na qualidade dos resultados. Comparando as características pertencentes ao mesmo cluster hierárquico, em ordem de similaridade:

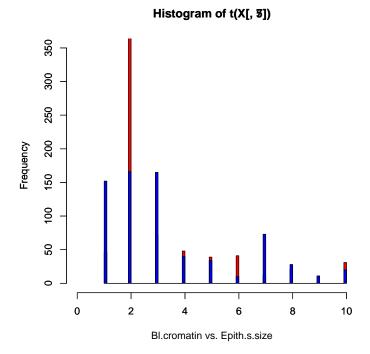
>

- > hist(t(X[,3]),col='red',xlab='Bl.cromatin vs. Cell.shape',breaks=100,ylim=c(0,350),xlim=c
- > par(new=T)
- > hist(t(X[,7]),col = 'blue', xlab='',breaks=100,ylim=c(0,350),xlim=c(0,10))

Histogram of t(X[, 3])

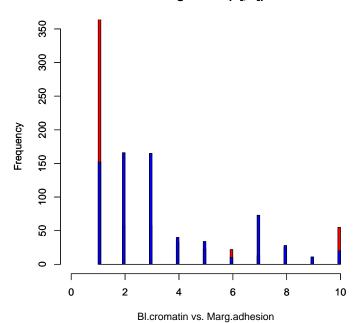


- > hist(t(X[,5]),col='red',xlab='Bl.cromatin vs. Epith.s.size',breaks=100,ylim=c(0,350),xlim=> par(new=T)
- > hist(t(X[,7]),col = 'blue', xlab='',breaks=100,ylim=c(0,350),xlim=c(0,10))



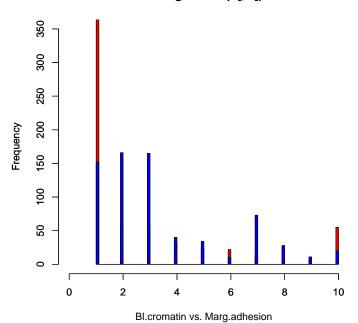
- > hist(t(X[,4]),col='red',xlab='Bl.cromatin vs. Marg.adhesion',breaks=100,ylim=c(0,350),xlim
- > par(new=T)
- > hist(t(X[,7]),col = 'blue', xlab='',breaks=100,ylim=c(0,350),xlim=c(0,10))

Histogram of t(X[, ₮])



- > hist(t(X[,4]),col='red',xlab='Bl.cromatin vs. Marg.adhesion',breaks=100,ylim=c(0,350),xlim
- > par(new=T)
- > hist(t(X[,7]),col = 'blue', xlab='',breaks=100,ylim=c(0,350),xlim=c(0,10))

Histogram of t(X[, ₮])



- > hist(t(X[,8]),col='red',xlab='B1.cromatin vs. Normal.nucleoli',breaks=100,ylim=c(0,350),xl
- > par(new=T)
- > hist(t(X[,7]),col = 'blue', xlab='',breaks=100,ylim=c(0,350),xlim=c(0,10))

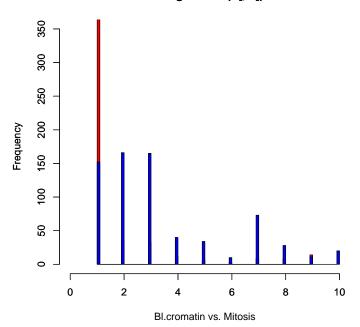
Bl.cromatin vs. Normal.nucleoli

> hist(t(X[,9]),col='red',xlab='B1.cromatin vs. Mitosis',breaks=100,ylim=c(0,350),x

> par(new=T)

> hist(t(X[,7]),col = 'blue', xlab='',breaks=100,ylim=c(0,350),xlim=c(0,10))

Histogram of t(X[, 9])

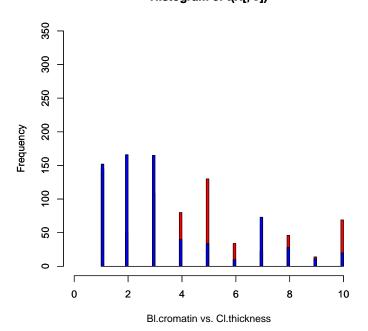


Comparando entre clusters:

```
> ###########################
```

- > hist(t(X[,1]),col='red',xlab='B1.cromatin~vs.~Cl.thickness',breaks=100,ylim=c(0,350),xlim=c(0,35
- > par(new=T)
- > hist(t(X[,7]),col = 'blue', xlab='',breaks=100,ylim=c(0,350),xlim=c(0,10))

Histogram of t(X[, 7])



- > hist(t(X[,6]),col='red',xlab='Bl.cromatin vs. Bare.nuclei',breaks=100,ylim=c(0,350),xlim=c
- > par(new=T)
- > hist(t(X[,7]),col = 'blue', xlab='',breaks=100,ylim=c(0,350),xlim=c(0,10))

Histogram of t(X[, §])

4

Bl.cromatin vs. Bare.nuclei

 ${\it Observa-se \ que} \\ {\it Cl.thickness a presenta uma distribuição mais próxima do cluster ao qual Bl.crompatin pertence, se comparada a Bare.nuclei.}$

6

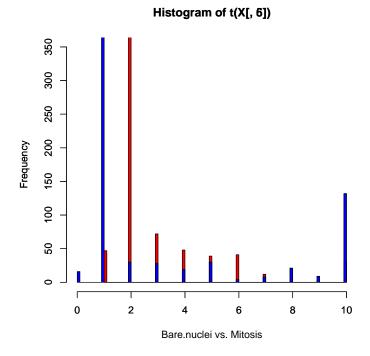
2

0

> hist(t(X[,5]),col='red',xlab='Bare.nuclei vs. Mitosis',breaks=100,ylim=c(0,350),xlim=c(0,550), par(new=T)

10

> hist(t(X[,6]),col = 'blue', xlab='',breaks=100,ylim=c(0,350),xlim=c(0,10))



Comparação intra-cluster:

```
> ###########################
```

- $> hist(t(X[,1]),col='red',xlab='Bare.nuclei\ vs.\ Cl.thickness',breaks=100,ylim=c(0,350),xlim=c(0,$
- > par(new=T)
- > hist(t(X[,6]),col = 'blue', xlab='',breaks=100,ylim=c(0,350),xlim=c(0,10))

